Documento de apoyo (Sesión 10, Unidad 2)

Fundamentos de regresión, clasificación y evaluación de modelos predictivos

Teoría aplicada a BigQuery ML y al Proyecto 2 de NYC Taxi Trips 2022

Javier Andrés Valdez González / Auxiliar

Seminario de Sistemas 2 — Sección P

Universidad de San Carlos de Guatemala

Abril de 2026

Resumen

El análisis exploratorio de datos permite describir el comportamiento histórico de un fenómeno, pero no basta por sí solo cuando se busca anticipar resultados futuros o automatizar decisiones. En ese punto entran los modelos predictivos, cuya función es aprender relaciones entre variables observadas y una variable objetivo para luego aplicarlas sobre registros no vistos durante el entrenamiento. Este documento desarrolla, con enfoque técnico-académico, la teoría de los problemas de regresión y clasificación, el papel de las variables de entrada y salida, la noción de entrenamiento, evaluación y generalización, y la importancia de separar adecuadamente los datos para evitar sobreajuste y fuga de información. Asimismo, se explican las métricas fundamentales de clasificación y regresión, su interpretación práctica, y la forma en que estas ideas se aterrizan en un flujo con BigQuery ML y SQL sobre el dataset NYC Taxi Trips 2022.

Palabras clave: regresión, clasificación, evaluación de modelos, BigQuery ML, precisión, matriz de confusión, error cuadrático medio, overfitting.

Índice

1. Introducción **4**

2. Modelado predictivo: propósito y estructura conceptual **5**
2.1. De la descripción a la predicción 5
2.2. Variables de entrada, variable objetivo y observación 5

3. Regresión y clasificación **6**
3.1. Problemas de regresión 6
3.2. Problemas de clasificación 6
3.3. Por qué el proyecto pide dos modelos 6

4. Entrenamiento, evaluación y generalización **7**
4.1. Qué significa entrenar un modelo 7
4.2. Qué significa evaluar 7
4.3. Generalización y sobreajuste 7

5. Separación de datos y fuga de información **8**
5.1. Conjuntos de entrenamiento, evaluación y predicción 8
5.2. Data leakage 8

6. Ingeniería de características **9**

7. Métricas para clasificación **10**
7.1. Matriz de confusión 10
7.2. Accuracy 10
7.3. Precision 10
7.4. Recall 11
7.5. F1-score 11
7.6. ROC y ROC-AUC 11

8. Métricas para regresión **12**
8.1. Error y función de pérdida 12
8.2. MAE 12
8.3. MSE 12
8.4. RMSE 12
8.5. R^2 13

9. Comparación entre modelos y selección **14**

10. Aplicación sobre nuevos datos **15**

11. Aterrizaje de la teoría al Proyecto 2 **16**

11.1. Modelo de clasificación 16

11.2. Modelo de regresión 16

11.3. Justificación de variables 16

12. Errores conceptuales frecuentes **17**

13. Conclusiones **18**

1. Introducción

En analítica de datos, no todas las preguntas tienen la misma naturaleza. Algunas buscan describir el pasado, como identificar qué horas concentran mayor volumen de viajes o qué rutas generan más ingresos. Otras persiguen un objetivo diferente: usar la información histórica para inferir o estimar resultados futuros. Este segundo grupo de preguntas define el terreno del aprendizaje supervisado, donde un modelo se entrena con ejemplos etiquetados y luego se utiliza sobre datos nuevos [1], [11].

Desde la perspectiva del curso, el requisito de entrenar dos modelos distintos no debe entenderse como una exigencia meramente operativa, sino como una oportunidad para demostrar que el estudiante puede recorrer un ciclo completo de modelado: formulación del problema, construcción de variables, entrenamiento, evaluación, comparación y aplicación de resultados. En BigQuery ML, este ciclo se materializa mediante SQL, lo que reduce la fricción técnica pero no reemplaza la necesidad de comprender los fundamentos conceptuales [2], [5].

2. Modelado predictivo: propósito y estructura conceptual

2.1. De la descripción a la predicción

El análisis descriptivo resume lo que ya ocurrió. En cambio, un modelo predictivo intenta aproximar una función que relacione variables observadas con una variable objetivo. Si se dispone de suficientes ejemplos históricos, el algoritmo ajusta parámetros internos para encontrar patrones útiles y luego reutiliza ese patrón en observaciones no vistas [1].

En un escenario de taxis, una observación corresponde a un viaje individual. Ese viaje contiene atributos como hora de abordaje, distancia, forma de pago, tarifa y zonas de origen y destino. La idea del modelo consiste en aprender cómo esos atributos se relacionan con una etiqueta de interés, por ejemplo el monto de propina o la probabilidad de que la propina sea alta.

2.2. Variables de entrada, variable objetivo y observación

Todo problema supervisado puede descomponerse en tres elementos:

M1. Observación: la unidad de análisis. En este proyecto es un viaje de taxi.

M2. Variables de entrada o *features*: columnas conocidas que describen la observación y que el modelo puede usar para predecir.

M3. Variable objetivo o *label*: el resultado que se quiere estimar.

La claridad en esta separación es crítica. Si el objetivo es predecir `tip_amount`, entonces el problema es de regresión. Si el objetivo es clasificar un viaje como `is_high_tip = 1` o `0`, entonces el problema es de clasificación. Confundir ambas cosas conduce a elegir métricas o algoritmos incorrectos [10].

3. Regresión y clasificación

3.1. Problemas de regresión

La regresión se utiliza cuando la salida esperada es un valor numérico continuo. No se busca decidir una categoría, sino aproximar un valor. En el contexto del proyecto, predecir el monto de la propina es un problema de regresión: el valor real puede ser 0.50, 3.75, 7.20 o cualquier otra cantidad dentro de un rango razonable [8].

La calidad del modelo depende de la distancia entre el valor predicho y el valor real. Por esa razón, la evaluación de regresión se basa en métricas de error, no en conteos de aciertos y errores discretos.

3.2. Problemas de clasificación

La clasificación se utiliza cuando la salida esperada pertenece a una clase o categoría. En la forma más simple, se trata de clasificación binaria, donde la etiqueta solo puede tomar dos valores. Si un viaje se marca como "propina alta" o "no propina alta", el problema consiste en asignar correctamente una observación a una de esas dos clases [2], [7].

Un clasificador binario no solo produce una clase, sino generalmente una probabilidad. La clase final surge al comparar esa probabilidad con un umbral. Si la probabilidad supera el umbral, el modelo clasifica como positivo; en caso contrario, como negativo [12].

3.3. Por qué el proyecto pide dos modelos

Pedir dos modelos persigue tres fines pedagógicos:

- obligar al estudiante a justificar una formulación del problema;
- promover la comparación entre alternativas, en lugar de asumir que un solo modelo basta;
- evidenciar que la evaluación depende del tipo de tarea y de las métricas apropiadas.

En términos prácticos, una combinación natural para este proyecto es:

- un modelo de clasificación para determinar si la propina será alta;
- un modelo de regresión para estimar el monto de la propina.

4. Entrenamiento, evaluación y generalización

4.1. Qué significa entrenar un modelo

Entrenar un modelo significa ajustar sus parámetros internos usando ejemplos históricos donde ya se conoce la salida correcta. El algoritmo recibe columnas de entrada y la variable objetivo, y trata de encontrar una relación que minimice el error o maximice la capacidad de discriminación según el tipo de tarea [2], [9].

En BigQuery ML este proceso se implementa mediante `CREATE MODEL`. Aunque la sintaxis pueda parecer simple, conceptualmente el motor está resolviendo un problema de optimización: busca parámetros que hagan que las predicciones se aproximen lo más posible a la realidad observada [2].

4.2. Qué significa evaluar

Evaluar implica medir qué tan bien se comporta el modelo sobre datos que no fueron utilizados para aprender. Esa distinción es fundamental. Un modelo puede ajustarse perfectamente a los datos de entrenamiento y aun así fracasar cuando se le presentan ejemplos nuevos [1], [11].

4.3. Generalización y sobreajuste

Se dice que un modelo generaliza bien cuando mantiene buen desempeño fuera del conjunto de entrenamiento. El problema opuesto es el sobreajuste (*overfitting*), que ocurre cuando el modelo aprende patrones reales mezclados con ruido, peculiaridades accidentales o memorias del conjunto de entrenamiento, deteriorando así su utilidad práctica sobre datos nuevos [11].

En escenarios de negocio, un modelo sobreajustado puede lucir excelente en pruebas internas mal diseñadas y ser inútil en producción. Por eso la evaluación debe realizarse sobre observaciones no vistas.

5. Separación de datos y fuga de información

5.1. Conjuntos de entrenamiento, evaluación y predicción

Una práctica estándar consiste en dividir los datos en subconjuntos con funciones diferentes:

- **Training set:** usado para entrenar;
- **Evaluation set o validation set:** usado para medir desempeño fuera del entrenamiento;
- **Prediction set:** datos nuevos sobre los que se aplica el modelo ya entrenado.

En el proyecto se propone una división temporal: meses iniciales para entrenamiento, meses intermedios para evaluación y el último bloque para predicción. Esta estrategia tiene sentido porque el fenómeno observado es temporal y la intención es simular un escenario real donde se aprende con el pasado y se predice sobre el futuro [1].

5.2. Data leakage

La fuga de información ocurre cuando el modelo recibe, de forma directa o indirecta, información que en el mundo real no estaría disponible al momento de predecir. El resultado es un desempeño artificialmente alto [1], [11].

Existen dos fuentes comunes de fuga:

L1. Variables contaminadas: columnas que contienen o anticipan la respuesta.

L2. Partición incorrecta del tiempo: mezclar pasado y futuro al evaluar, especialmente en datos secuenciales.

En el proyecto, separar por meses es una medida concreta para reducir fuga temporal.

6. Ingeniería de características

La ingeniería de características (*feature engineering*) consiste en transformar datos crudos en variables más útiles para el modelo. En muchos casos, las columnas originales no son la representación más informativa del fenómeno [2].

Ejemplos adecuados en el dataset de taxis son:

- extraer `pickup_hour` de `pickup_datetime`;
- derivar `pickup_day_of_week`;
- calcular `trip_duration_minutes` como diferencia entre abordaje y descenso;
- definir `tip_pct` como relación entre propina y tarifa;
- construir `is_high_tip` a partir de un umbral sobre `tip_pct`.

La razón técnica es clara: al crear variables derivadas, el modelo accede a una representación más alineada con patrones útiles. Un timestamp completo puede ser demasiado específico, mientras que la hora del día o el día de la semana pueden capturar mejor regularidades de comportamiento.

7. Métricas para clasificación

7.1. Matriz de confusión

La matriz de confusión resume el desempeño de un clasificador binario en cuatro tipos de resultado: verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos [3], [12]. Esta representación es valiosa porque no solo indica cuántos aciertos hubo, sino también qué tipo de errores comete el modelo.

Si la clase positiva es "propina alta", entonces:

- **Verdadero positivo (TP):** el modelo predijo propina alta y era correcto;
- **Verdadero negativo (TN):** el modelo predijo no propina alta y era correcto;
- **Falso positivo (FP):** el modelo afirmó propina alta cuando no correspondía;
- **Falso negativo (FN):** el modelo no detectó un caso que sí era propina alta.

7.2. Accuracy

La exactitud global o *accuracy* mide la proporción total de predicciones correctas:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Es una métrica fácil de interpretar, pero puede ser engañosa en conjuntos desbalanceados, porque un modelo puede acertar casi siempre a la clase mayoritaria y aun así ser poco útil para detectar la minoritaria [7].

7.3. Precision

La precisión responde a la pregunta: "de todos los casos que el modelo clasificó como positivos, cuántos realmente lo eran?" Su fórmula es:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Es importante cuando el costo de los falsos positivos es alto [7], [10].

7.4. Recall

El *recall* o sensibilidad responde a la pregunta: "de todos los casos positivos reales, cuántos fue capaz de detectar el modelo?" Su fórmula es:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Se vuelve crucial cuando el costo de perder positivos reales es elevado [7].

7.5. F1-score

El F1-score combina precisión y recall en una sola medida:

$$F1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Resulta especialmente útil cuando se busca equilibrio entre ambas métricas y cuando el conjunto de clases no está balanceado [7].

7.6. ROC y ROC-AUC

La curva ROC estudia el comportamiento del clasificador para distintos umbrales. En lugar de asumir un único punto de corte, analiza cómo cambia la tasa de verdaderos positivos frente a la tasa de falsos positivos [6], [12]. El área bajo la curva, conocida como AUC, resume la capacidad global del modelo para discriminar entre clases. Valores cercanos a 1 sugieren alta separación; valores cercanos a 0.5 indican comportamiento similar al azar [10].

8. Métricas para regresión

8.1. Error y función de pérdida

En regresión, la pregunta no es si una clase fue correcta o incorrecta, sino qué tan lejos está la predicción del valor real. Esa distancia se expresa mediante el error:

$$\text{error} = y - \hat{y}$$

Las métricas de regresión resumen la magnitud de esos errores en un conjunto de observaciones [8].

8.2. MAE

El error absoluto medio (*Mean Absolute Error*) promedia el valor absoluto de los errores. Tiene una ventaja interpretativa: se expresa en las mismas unidades de la variable objetivo. Si la etiqueta está en dólares, el MAE también está en dólares [8].

8.3. MSE

El error cuadrático medio (*Mean Squared Error*) promedia el cuadrado de los errores. Al elevar al cuadrado, penaliza con mayor severidad los errores grandes, por lo que resulta sensible a valores atípicos:

$$\text{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

Esta métrica es importante tanto desde el punto de vista de evaluación como desde el entrenamiento, porque muchos modelos de regresión optimizan variantes del error cuadrático [8], [10].

8.4. RMSE

La raíz del error cuadrático medio (*Root Mean Squared Error*) devuelve el error a la escala original de la etiqueta:

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Su interpretación suele ser más intuitiva que la del MSE puro, aunque conserva la fuerte penalización de errores grandes [8].

8.5. R^2

El coeficiente de determinación mide qué proporción de la variabilidad del objetivo logra explicar el modelo. Aunque es una métrica útil como resumen general, no debe interpretarse de manera aislada. Un buen análisis de regresión debería revisar al menos una métrica de escala interpretable como MAE o RMSE además de R^2 [4].

9. Comparación entre modelos y selección

La comparación de modelos no debería reducirse a "escoger el que tenga el número más alto" sin contexto. La selección debe considerar:

- el tipo de problema;
- la métrica más alineada con el objetivo;
- los costos relativos de los distintos errores;
- la estabilidad del modelo sobre datos no vistos;
- la interpretabilidad y facilidad de comunicar resultados.

Por ejemplo, un clasificador con *accuracy* alta pero *recall* muy bajo podría ser inaceptable si el objetivo es detectar correctamente los casos positivos. De manera análoga, un modelo de regresión con buen R^2 pero MAE muy alto puede ser poco útil operativamente.

10. Aplicación sobre nuevos datos

La frase "aplicarlo sobre nuevos datos" implica usar el modelo ya entrenado en observaciones no utilizadas durante el aprendizaje. En BigQuery ML esto ocurre con `ML.PREDICT` [5]. Conceptualmente, esta etapa verifica el propósito práctico del modelo: no basta con explicar el pasado; debe ser posible usar lo aprendido para generar predicciones en registros futuros o no vistos.

En el Proyecto 2, esa idea se operacionaliza al reservar el último bloque temporal para predicción. De ese modo, la secuencia es coherente:

P1. entrenar con meses anteriores;

P2. evaluar con un subconjunto posterior;

P3. aplicar el modelo sobre el tramo final del año.

11. Aterrizaje de la teoría al Proyecto 2

La formulación propuesta en el proyecto puede justificarse del siguiente modo:

11.1. Modelo de clasificación

Se define una etiqueta binaria, por ejemplo `is_high_tip`, que indica si la propina relativa supera cierto umbral. El modelo intenta responder si un viaje pertenece o no a la clase positiva. Las métricas relevantes son precisión, recall, F1-score, ROC-AUC y matriz de confusión [3], [6], [7].

11.2. Modelo de regresión

Se usa `tip_amount` como variable objetivo continua. El modelo intenta estimar un monto numérico de propina. Las métricas relevantes son MAE, MSE, RMSE y, de forma complementaria, R^2 [4], [8].

11.3. Justificación de variables

Variables como `trip_distance`, `fare_amount`, `pickup_hour`, `payment_type` y las zonas de abordaje/descenso tienen justificación razonable porque reflejan condiciones del viaje que potencialmente influyen en el monto o patrón de propina. La etapa de ingeniería de características permite convertir estas observaciones en señales más útiles para el modelo.

12. Errores conceptuales frecuentes

E1. Usar accuracy como única métrica de clasificación. Puede ocultar problemas graves en conjuntos desbalanceados.

E2. Evaluar con datos de entrenamiento. Impide medir generalización.

E3. Ignorar la fuga de información. Produce resultados artificialmente optimistas.

E4. No justificar la variable objetivo. Desconecta el modelo del problema real.

E5. Confundir regresión con clasificación. Conduce a interpretar mal los resultados y a elegir métricas impropias.

13. Conclusiones

La teoría detrás del requisito de entrenar dos modelos y evaluarlos con métricas adecuadas responde a una lógica fundamental del aprendizaje supervisado: los datos históricos se convierten en un insumo para aprender patrones, esos patrones se formalizan en modelos, y el valor real del proceso se verifica cuando las predicciones se sostienen sobre datos no vistos [1], [5].

En términos académicos, este tipo de práctica obliga a distinguir entre descripción y predicción, entre variables de entrada y objetivo, entre entrenamiento y evaluación, y entre buenos resultados aparentes y capacidad real de generalización. En términos aplicados, permite transformar un conjunto masivo de viajes en una base para anticipar comportamientos útiles, justificar decisiones analíticas y comunicar resultados con evidencia medible.

Referencias

[1] Google Cloud. «BigQuery ML model evaluation overview,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/evaluate-overview

[2] Google Cloud. «The CREATE MODEL statement for generalized linear models,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-create-glm

[3] Google Cloud. «The ML.CONFUSION_MATRIX function,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-confusion

[4] Google Cloud. «The ML.EVALUATE function,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-evaluate

[5] Google Cloud. «The ML.PREDICT function,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-predict

[6] Google Cloud. «The ML.ROC_CURVE function,» visitado 15 de abr. de 2026. dirección: https://cloud.google.com/bigquery/docs/reference/standard-sql/bigqueryml-syntax-roc

[7] Google for Developers. «Classification: Accuracy, recall, precision, and related metrics,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall

[8] Google for Developers. «Linear regression: Loss,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/crash-course/linear-regression/loss

[9] Google for Developers. «Logistic regression: Loss and regularization,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/crash-course/logistic-regression/loss-regularization

[10] Google for Developers. «Machine Learning Glossary: Metrics,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/glossary/metrics

[11] Google for Developers. «Overfitting,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/crash-course/overfitting/overfitting

[12] Google for Developers. «Thresholds and the confusion matrix,» visitado 15 de abr. de 2026. dirección: https://developers.google.com/machine-learning/crash-course/classification/thresholding